

Corso di Laurea in Ingegneria e Scienze Informatiche

Integrazione di RAG e LLM nello Sviluppo del Software

Tesi di laurea in:
PROGRAMMAZIONE AD OGGETTI

Relatore

Prof. Viroli Mirko

Candidato

Bollini Simone

Correlatore

Dott. Aguzzi Gianluca

Abstract

I Large Language Model (LLM) addestrati per sviluppare il codice sono oggi altamente efficaci e in grado di generare soluzioni di qualità. L'addestramento fatto sui modelli è però su fonti generali, questo non dà quindi la possibilità al modello di generare soluzioni su misura per una specifica richiesta utilizzando codice già creato dal programmatore o dalla propria azienda per casi simili. Da questo nasce l'esigenza di addestrare il modello per personalizzare le soluzioni proposte, contestualizzandole alla propria realtà aziendale e al proprio stile nel programmare ma il fine-tuning di un LLM è un processo molto costoso e difficile da utilizzare per mantenere aggiornato frequentemente la base di conoscenza del modello. Per rispondere a questa esigenza entra in gioco la Retrieval-Augmented Generation (RAG), che permette di aumentare la conoscenza del modello, recuperando informazioni da una propria base di conoscenza, esterna al modello, come librerie specifiche di un'azienda, arricchendo il prompt della query di input che sarà elaborata dal LLM. Il RAG, ricercando semanticamente i chunk maggiormente somiglianti a quanto richiesto se trovati, li inserirà per aumentare il prompt del LLM, estendendo la base di informazioni sulla quale genererà l'output con la risposta. Questa tesi approfondisce questi concetti e sperimenta l'integrazione di un RAG specifico per codice Java e un LLM con lo scopo di ottenere risposte personalizzate che solo con la conoscenza del LLM, anche se estremamente performante e completo, sarebbe stato impossibile ottenere.


*A Giulia e ai miei figli, il dono più incredibile di questa vita.
Alla mia grande famiglia.*

Grazie

Contents

Abstract	iii
1 Introduzione	1
1.1 Essere programmatori nel 2025	1
2 Addestrare un LLM per la Generazione del Codice	5
2.1 Scelta Modello	5
2.2 Raccolta e Preparazione dei Dataset	6
2.2.1 Pulizia e Pre-Processo	6
2.3 Pre-Addestramento	7
2.4 Fine-Tuning	7
2.4.1 Tecniche di Apprendimento	8
2.4.2 Overfitting	8
2.5 Pre-Addestramento vs Fine-Tuning	8
2.6 Valutazione e Ottimizzazione	9
2.6.1 Metriche di Valutazione	9
2.6.2 Tecniche di Ottimizzazione	9
3 RAG	11
3.1 Introduzione	11
3.2 Funzionamento	12
3.2.1 Creazione Vector Database	13
3.2.2 Fase 1: User query e function calling	14
3.2.3 Fase 2: Recupero delle Informazioni	14
3.2.4 Fase 3: Aumento del Prompt	15
3.3 Perchè RAG	15
4 Implementazione di un sistema RAG per lo sviluppo di codice per il linguaggio Java	17
4.1 Obiettivo	17
4.2 Architettura del Sistema	18

CONTENTS

4.3	Software Utilizzati	19
4.3.1	Ollama 	19
4.3.2	Llama 3.2	19
4.3.3	Codeqwen 1.5	20
4.3.4	LangChain	20
4.3.5	BGE-M3	20
4.3.6	FAISS	20
4.4	Dataset	20
4.5	Scenario base del Caso Studio	21
4.5.1	Codice di riferimento per rispondere alla query	21
4.5.2	Risultato Atteso	22
4.6	Implementazione	22
4.6.1	Creazione dei Chunk	22
4.6.2	Arricchire i chunk con metadati relativi al codice	26
4.6.3	Generazione degli Embedding	27
4.6.4	Esecuzione di query sul Database FAISS	28
4.6.5	Creazione della Pipeline RAG	30
4.7	Test Sistema RAG	33
4.7.1	Query base senza riferimenti al metodo utilizzato all'interno di segnaleWow	33
4.7.2	Query Completa con riferimenti al metodo utilizzato all'interno di segnaleWow	35
4.7.3	Commento risultati ottenuti	35
4.8	Valutazione del RAG con llm as a judge	36
4.8.1	Domande	36
4.8.2	Punteggio delle domande	40
4.8.3	Valutazione risultati risposte sistema RAG	43
5	Conclusioni	45
5.1	Impatto sullo Sviluppo Software	45
5.2	Sfide e Prospettive Future	45
		47
	Bibliography	47

Chapter 1

Introduzione

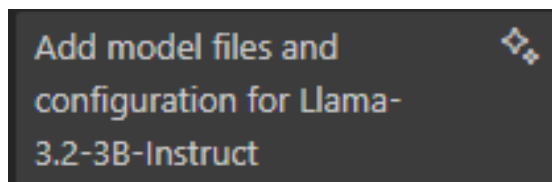
1.1 Essere programmatori nel 2025

Per sviluppare codice sono disponibili tantissimi (IDE), uno di questi è **Visual Studio Code**, mentre per condividere i progetti e lavorare in team lo strumento utilizzato potrebbe essere **GitHub**. Se richiesta memoria GPU per piccoli progetti accademici è possibile utilizzare **COLAB**, che permette di eseguire in remoto codice Python utilizzando GPU senza costi. Questi esempi sono parte di una panoramica di strumenti sempre più vasta, complessa e in rapita evoluzione, con un frequente cambio di software per realizzare un programma. Inoltre i possibili modi per realizzare i progetti è aumentata, disponendo oggi di sempre più librerie e metodi per ottenere risultati finali simili. Un esempio d'utilizzo degli strumenti sopra elencati potrebbe seguire la seguente scaletta:

- Realizzazione iniziale del progetto in locale utilizzando Visual Studio Code
- Push del codice su GitHub per condividere il progetto con il team
- Esecuzione del codice su Colab per testare il codice su GPU ed eventualmente eseguire modifiche concluse con nuovo Push su GitHub
- Pull in locale per continuare a lavorare sul progetto

Questo modo dinamico di lavorare è recente ma non una novità, come invece lo sono alcuni specifici strumenti forniti da questi software. Questi strumenti sono

tutti accumulati dall'implementazione al loro interno di funzioni basate sull'IA. Queste funzioni sono in grado di completare il codice, suggerire correzioni e creare documentazione pertinente. **GitHub** ha introdotto **Copilot**, un assistente IA per la scrittura del codice, questo strumento è integrabile con vari IDE tra cui proprio **Visual Studio Code**. Un esempio semplice ma che offre già un'idea della vastità e della potenza di queste funzioni è l'utility di **Github Copilot**: *'Generate Commit Message with Copilot'* che propone il testo da utilizzare come descrizione di un commit, ho provato a verificare quanto fosse contestualizzato e coerente con le modifiche apportate al codice ed ho ottenuto il seguente risultato:



```
Add model files and
configuration for Llama-
3.2-3B-Instruct
```

Nel mio caso quanto proposto era corretto ed ho quindi eseguito il Commit con la descrizione proposta. Quanto è riuscito a fare Copilot è strabiliante, in pochi istanti ha analizzato il contesto ritornando come output una risposta semplice ma coerente rispetto a quanto cambiato. L'uso di questi strumenti sta rendendo il lavoro molto più dinamico e veloce, riducendo le interruzioni nel cercare soluzioni o per trovare le giuste parole per descrivere quanto fatto.



L'intelligenza artificiale sta rivoluzionando il modo in cui il software viene sviluppato, strumenti come Copilot utilizzando tutto il loro potenziale, possono creare la spina dorsale di un progetto in poco tempo lasciando al programmatore il compito di verificare e correggere solo in parte il codice proposto. In progetti complessi questo non riduce il ruolo del programmatore, anzi lo eleva a compiti di precisione e ad alto valore aggiunto delegando la stesura di parti del codice semplici e ripetitive al software stesso. Per questi motivi capire come funzionano oggi questi strumenti è importante, sapere come chiedere e formulare correttamente le domande al LLM è fondamentale, esplicitando nel dettaglio con parole chiave mirate come deve essere realizzato il codice per indirizzarlo nell'elaborazione e ragionamento corretto. Altro compito complesso per il programmatore è non farsi troppo ammaliare dalle soluzioni proposte perché non sempre necessarie per quanto richiesto oppure diverse da quanto già conosciuto per realizzare una determinata funzione. Questo nuovo modo di lavorare permette di conoscere nuove soluzioni ma comporta test e tempo non sempre disponibile, il programmatore deve sempre avere il controllo del progetto, accettando generazione del codice automatica solo dove consapevole di quanto proposto e del suo impatto anche in casi di revisione e manutenzione futuri. Il codice deve rimanere rapidamente leggibile e coerente in tutte le sue parti, far generare il codice in automatico può portare ad una perdita di coerenza e leggibilità. Proprio per questo l'ultimo miglio da percorrere per sfruttare questi strumenti è la personalizzazione delle risposte del LLM, per ottenere risposte rimanendo nel contesto e nello stile di quanto già realizzato e conosciuto, per fare questo entra in gioco il **Fine-Tuning** e i **RAG** che verranno ampiamente approfonditi.

Chapter 2

Addestrare un LLM per la Generazione del Codice

L'addestramento di LLM per la generazione del codice di programmazione richiede una serie di passaggi complessi e costi significativi. Conoscere questo processo è utile per poter poi comprendere al meglio la successiva implementazione con le tecniche di **RAG**. La procedura si divide nelle seguenti fasi:

2.1 Scelta Modello

Gli LLM utilizzano tipicamente architetture basate su trasformatori, che sono particolarmente efficaci nell'elaborazione di sequenze di dati, come il testo e il codice. I trasformatori utilizzano meccanismi di auto-attenzione per valutare l'importanza di diversi elementi in una sequenza, permettendo al modello di comprendere le relazioni tra parole o token. Questa capacità è fondamentale nella generazione del codice, poiché le dipendenze tra variabili e funzioni possono estendersi su ampie sezioni del codice, richiedendo al modello di considerare un ampio contesto per trovare le risposte corrette. L'architettura del modello scelto influenzerà in maniera decisiva tutte le successive fasi di addestramento. È utile notare che sebbene i trasformatori siano attualmente lo standard, esistono anche altri approcci come le reti neurali ricorrenti (RNN e LSTM) e nuove tecniche in continua evoluzione come i Large Concept Models [WFS⁺24].

2.2 Raccolta e Preparazione dei Dataset

La qualità e la quantità dei dati per l'addestramento è di primaria importanza per preparare un modello alla generazione di codice in maniera efficace. È quindi essenziale utilizzare per il training codice proveniente da molteplici fonti tra cui codice sorgente, file readme, documentazione tecnica, commenti nel codice, pagine Wiki, API e discussioni su forum specializzati in programmazione, arricchendo così il dataset con esempi pratici e ricchezza terminologica. In rete è possibile trovare diverso materiale open source tra cui dataset già etichettati. Alcuni dataset hanno un valore altissimo, per questo motivo per tutelare il costo speso per produrli per certi dataset è previsto il diritto d'autore. I dati si dividono in due tipologie:

- **Dati Strutturati:** seguono un formato specifico e predefinito, seguono la struttura in coppie (descrizione, codice).
- **Dati non Strutturati:** non sono organizzati e sono quindi più difficili da interpretare dal modello.

2.2.1 Pulizia e Pre-Processo

La raccolta di dati va visionata con cura, se non si conosce la provenienza del codice è possibile che contenga bug o codice obsoleto che possono essere trasmessi al modello. Con la rapida evoluzione del codice molte librerie e tecniche vengono **rapidamente deprecate** e superate per questo anche utilizzando i più noti modelli LLM ad oggi disponibili, può capitare di ricevere come output **codice obsoleto che risolve il quesito ma con soluzioni contenti tecniche, api e librerie deprecate o non più disponibili**. Per questo motivo i dati raccolti devono essere puliti e pre-processati per rimuovere errori e informazioni non pertinenti, garantendo così un dataset di alta qualità per l'addestramento.

Tokenizzazione

Il modello per poter elaborare il dataset ha bisogno che quest'ultimo venga diviso in parti più piccole chiamate token per mantenere l'integrità del dato [Sta24], i token possono essere parole, parti di parole o singoli caratteri, e questa suddivisione è fondamentale per:

- **Gestione del contesto:** mantenere la relazione semantica tra i diversi elementi del codice
- **Efficienza computazionale:** processare grandi quantità di testo in modo ottimizzato
- **Limitazioni del modello:** rispettare i limiti massimi di input del modello (tipicamente tra 512 e 4096 token)
- **Preservazione della struttura:** mantenere la struttura sintattica del codice sorgente

Ad esempio, nel codice Java, i token potrebbero includere:

- Parole chiave (`public`, `class`, `static`)
- Identificatori (nomi di variabili e metodi)
- Operatori e simboli (`+`, `=`, `{`, `}`)
- Stringhe letterali e commenti

2.3 Pre-Addestramento

Il pre-addestramento di un LLM specializzato nella generazione di codice ha lo scopo di fornire al modello una conoscenza generale della sintassi e delle strutture logiche del linguaggio di programmazione. Durante questa fase il modello impara a generare codice partendo da dati non etichettati utilizzando tecniche come il *language modeling* autoregressivo per insegnare al modello di predire il token successivo in una sequenza. Questo approccio rende la generazione contestualmente e coerente di codice, sfruttando la capacità del modello di "ricordare" il contesto anche su ampie sequenze di dati.

2.4 Fine-Tuning

Il fine-tuning è la fase in cui il modello già pre-addestrato viene ulteriormente specializzato per la generazione di codice adattando e migliorando il modello per

specifici domini di applicazione. Durante questa fase, il modello affina le sue capacità attraverso dataset specializzati composti da coppie descrizione-codice, documentazione tecnica e commenti, esempi di bug-fixing e refactoring.

2.4.1 Tecniche di Apprendimento

:

- **Supervisionato:** Training su coppie input-output predefinite, il modello impara a mappare input di descrizione con linguaggio naturale a output di codice corrispondente.
- **Per Rinforzo:** Ottimizzazione basata su feedback e metriche di qualità
- **Few-shot Learning:** Adattamento a nuovi contesti con pochi esempi

2.4.2 Overfitting

Il processo di fine-tuning richiede un attento bilanciamento nell'apprendere dai dati di addestramento cercando di evitare di incorrere in overfitting. L'overfitting si verifica quando il modello si specializza troppo sui dati di addestramento, riducendo la sua capacità di generalizzazione producendo risposte errate o incoerenti su nuovi dati. Per evitare l'overfitting vengono utilizzati set di validazione, regolarizzazione e tecniche di dropout.

2.5 Pre-Addestramento vs Fine-Tuning

È importante comprendere la distinzione tra queste due fasi:

Pre-Addestramento

Il pre-addestramento è la fase iniziale dove il modello:

- Acquisisce una comprensione **generale** del linguaggio di programmazione
- Viene addestrato su **grandi quantità** di codice sorgente generico

- Impara le strutture base e la sintassi del linguaggio
- Non è ancora specializzato per compiti specifici

Fine-Tuning

Il fine-tuning è invece la fase di specializzazione dove il modello:

- Si adatta a un **dominio specifico** o a compiti particolari
- Utilizza dataset specifici e composti da dati strutturati

2.6 Valutazione e Ottimizzazione

Una volta addestrato, il modello deve essere rigorosamente valutato utilizzando metriche specifiche per la generazione di codice, come la correttezza sintattica, la funzionalità e l'efficienza del codice prodotto. I risultati della valutazione possono essere utilizzati per ulteriori ottimizzazioni, come aggiustamenti dei pesi del modello, modifiche all'architettura o includere dati di addestramento aggiuntivi per affrontare eventuali carenze.

2.6.1 Metriche di Valutazione

- **Correttezza Sintattica:** Verifica che il codice generato sia sintatticamente corretto.
- **Funzionalità:** Verifica che il codice generato realizzi la funzionalità desiderata.
- **Efficienza:** Valuta le prestazioni del codice in termini di tempo di esecuzione e utilizzo delle risorse.


2.6.2 Tecniche di Ottimizzazione

- **Aggiustamento dei Pesi:** Modifica dei pesi del modello per migliorare le prestazioni.

- **Modifiche all'Architettura:** Introduzione di nuove componenti o modifiche a quelle esistenti.
- **Integrazione di Dati Aggiuntivi:** Utilizzo di ulteriori dati di addestramento per migliorare le prestazioni.

Chapter 3

RAG



3.1 Introduzione

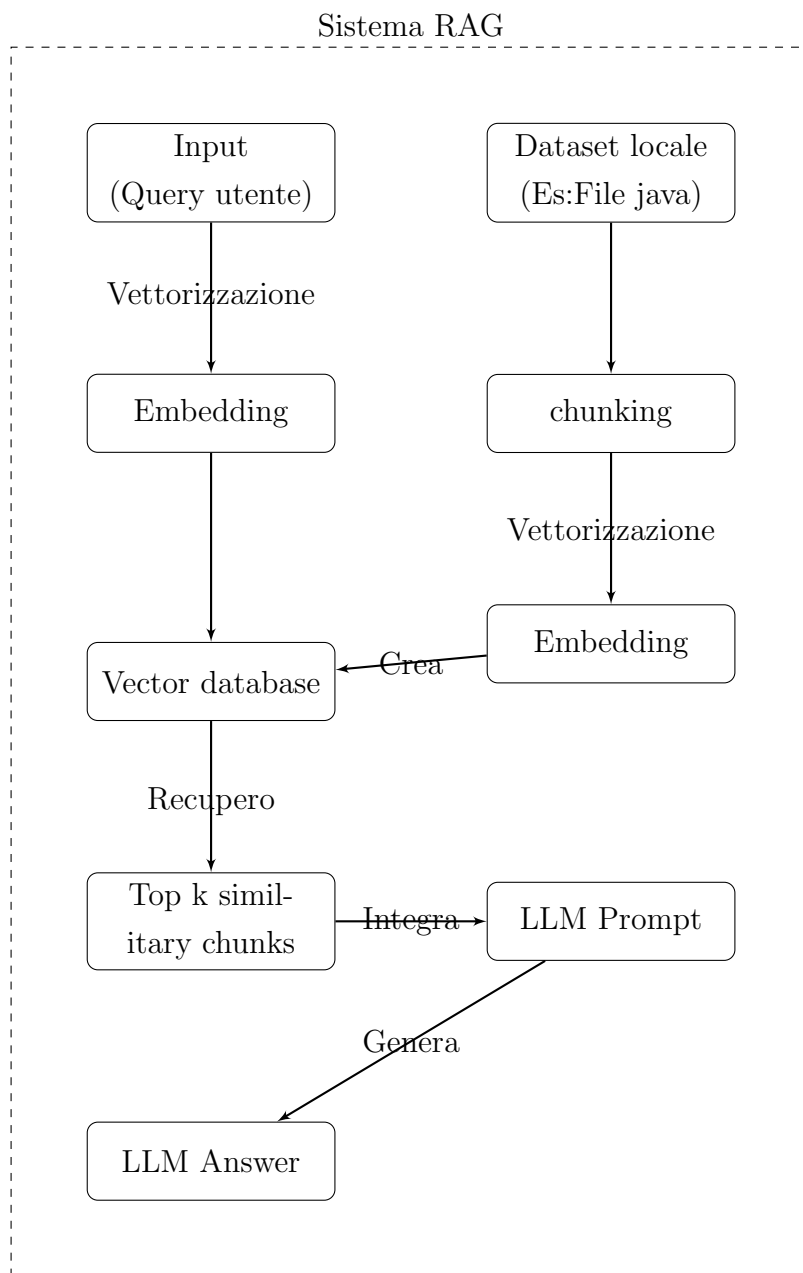
La sigla RAG rappresenta **Retrieval Augmented Generation**, (in italiano *Generazione Aumentata tramite Recupero*) è un sistema che permette di migliorare l'output di un LLM estendendo la sua conoscenza con nuove informazioni, al di fuori dai suoi dati di addestramento allo scopo di:

- ottenere risposte mirate e personalizzate contenenti knowledge relativa a librerie e codice custom
- migliorare il codice generato rendendolo più specifico al dominio riducendo le allucinazioni
- facilitare l'assistenza da parte del modello nella fase di debugging migliorando la sua comprensione di sistemi complessi

- supportare la creazione di documentazione aggiornata
- permettere all'interno di un Team di migliorare la coerenza del codice scritto da diversi programmatori proponendo librerie e standard comuni
- evitare risposte imprecise a causa della confusione terminologica, in cui diverse fonti utilizzano la stessa terminologia per parlare di cose diverse.

3.2 Funzionamento

Il sistema RAG si integra al LLM attivando un meccanismo di recupero delle informazioni per aumentare il prompt della richiesta. Il funzionamento si articola in diverse fasi qui sotto illustrate:



3.2.1 Creazione Vector Database

La propria *knowledge base* deve essere salvata in un database vettoriale, in modo da poter essere interrogata in maniera efficiente dal sistema RAG. Per creare questo database vengono utilizzati dati esterni al training set originale del LLM, proveni-

enti da diverse fonti come:

- API e database interni
- Archivi documentali
- File di testo e codice

La creazione di un database ben strutturato e la parte più importante di tutto il processo, dividere il codice in chunk correttamente etichettando ogni elemento con i corretti metadati è fondamentale per la successiva fase di interrogazione. Il processo di creazione del Vector Database segue la seguente pipeline:

- **Chunking**: Divisione del codice in chunk
- **Embedding**: Conversione dei chunk in vettori numerici
- **Vector Store**: Memorizzazione degli embedding in un database vettoriale

3.2.2 Fase 1: User query e function calling

Data la query d'input da parte dell'utente, il sistema RAG è avviato da una chiamata di funzione per ricercare nel **Vector Database** i chunk più rilevanti per la query. Nei modelli più complessi in RAG è di fatto un agente integrato nel sistema che viene chiamato all'occorrenza quando la base di conoscenza del LLM non è sufficiente per fornire una risposta adeguata, in questo modo viene anche razionalizzato e ottimizzato il costo computazionale del processo, attivato solo quando strettamente necessario. Rimane comunque questo passaggio una scelta configurabile in base allo specifico utilizzo del sistema, ad esempio per un'azienda che utilizza il LLM solo per compiti specifici e sempre contestualizzati può essere configurato il sistema in modo che chiami la funzione RAG sempre.


3.2.3 Fase 2: Recupero delle Informazioni

Quando l'utente sottopone una query:

- La domanda viene convertita in un vettore

3.3. PERCHÈ RAG

- Il sistema cerca nel database vettoriale le informazioni più pertinenti
- Viene calcolata la rilevanza attraverso calcoli matematici vettoriali
- Se trovate corrispondenze con uno score di similarità sufficiente, i chunk vengono recuperati



3.2.4 Fase 3: Aumento del Prompt

Se trovate, il sistema RAG arricchisce il prompt dell'utente con le informazioni recuperate, fornendo al LLM un contesto più ampio e dettagliato per generare una risposta coerente.

3.3 Perché RAG

Il RAG permette di superare le limitazioni di conoscenza dei LLM, fornendo risposte accurate e contestualizzate grazie all'integrazione di conoscenze interne e personalizzate. Dopo aver costruito un sistema RAG è possibile eseguire rapidamente aggiornamenti al **Vector database**, cosa che sarebbe molto più difficile da ottenere con il fine-tuning, che richiede tempo e risorse significative. Avere un LLM addestrato fin da subito su misura per le proprie esigenze e sempre aggiornato

sarebbe fantastico ma per quasi tutte le aziende richiederebbe risorse impossibili da sostenere ed è quindi molto più comune costruire un RAG che intervenire direttamente sulla conoscenza del LLM che restano solitamente proprietà di terzi.

Chapter 4

Implementazione di un sistema RAG per lo sviluppo di codice per il linguaggio Java

4.1 Obiettivo

Questo caso studio si propone l'obiettivo di verificare il livello di personalizzazione e qualità delle risposte di un LLM integrato con un sistema RAG. Potenziando la query nel prompt di input del LLM attraverso la creazione di un sistema RAG di supporto, verranno costruite e analizzate singolarmente tutte le fasi che compongono il processo. Il sistema RAG è stato testato con della **classi JAVA uniche** create appositamente per il caso studio.

Problematica da affrontare:

Chiamate a più livelli di classi e metodi, dove il RAG potrebbe non essere in grado di estrapolare le informazione necessarie da inserire nel prompt per ottenere dal LLM risposte coerenti con quanto richiesto.

4.2 Architettura del Sistema

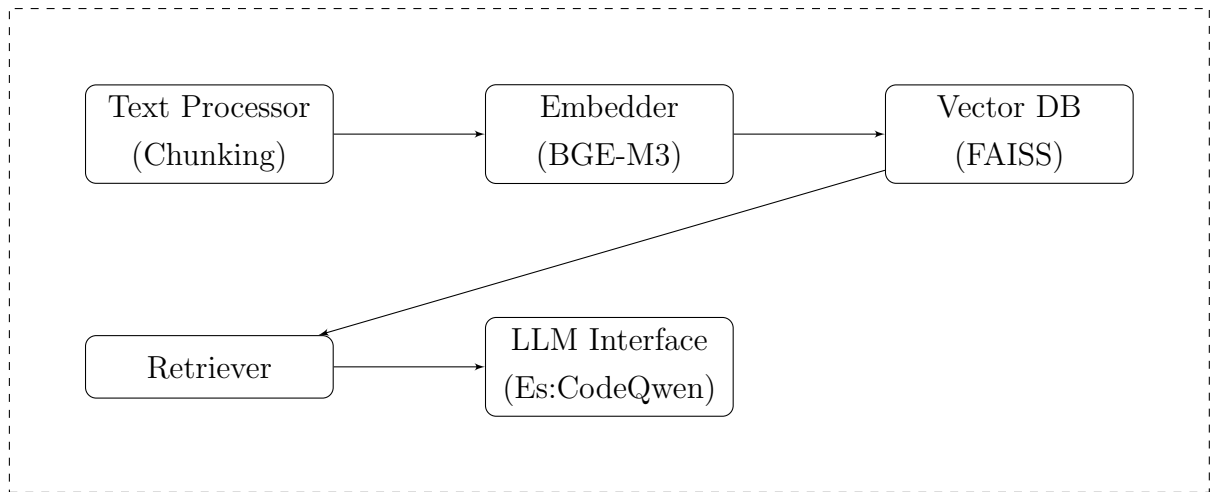


Figure 4.1: Architettura del sistema RAG

Il sistema RAG implementa un'architettura modulare composta da cinque componenti principali:

1. **Text Processor (Chunking):**

- Suddivide i file Java in chunk di un numero definito appositamente di token
- Gestisce sovrapposizione di token tra chunk
- Preserva il contesto del codice

2. **Embedder (BGE-M3):**

- Converte i chunk in vettori numerici
- Utilizza il modello BGE-M3 per la generazione degli embedding
- Normalizza i vettori per ottimizzare la ricerca

3. **Vector DB (FAISS):**

- Memorizza gli embedding in un database vettoriale

- Ottimizza la ricerca per similarità
- Garantisce recupero efficiente dei chunk rilevanti

4. Retriever:

- Esegue query semantiche sul database
- Recupera i k chunk più rilevanti
- Prepara il contesto per il LLM

5. LLM Interface (CodeQwen e Llama 3.2):

- Interfaccia tramite Ollama con i LLM CodeQwen e Llama 3.2
- Genera risposte basate sul contesto recuperato

4.3 Software Utilizzati

4.3.1 Ollama

Ollama [Oll24] è un software che permette di utilizzare in locale LLM senza dover dipendere da servizi cloud esterni. Il software è stato scelto per la sua flessibilità, permettendo di integrare facilmente i modelli LLM nel sistema RAG.

LLM

Ogni LLM è specializzato per determinati scopi, per questo motivo per rendere più completa la ricerca sono stati utilizzati due modelli con caratteristiche differenti:

4.3.2 Llama 3.2

Llama 3.2 3B [AI24b], un modello di linguaggio open source. Il modello, con 3 miliardi di parametri, è ottimizzato per compiti di dialogo multilingue e si distingue per le sue capacità di recupero e sintesi delle informazioni. La scelta è ricaduta su questa versione per il suo equilibrio tra prestazioni e requisiti computazionali che permettono il suo utilizzo senza hardware troppo potente.

4.3.3 Codeqwen 1.5

Codeqwen [Tea24b] è un modello di linguaggio open source specializzato nella generazione di codice e documentazione tecnica. Con 7 miliardi di parametri, il modello è stato addestrato su un ampio dataset di codice sorgente e documentazione tecnica, permettendo di generare codice coerente e ben strutturato. La scelta di questo modello è stata dettata, a differenza di llama3.2, dalla sua specializzazione nella programmazione e dalla sua capacità di generare codice di alta qualità.

4.3.4 LangChain

LangChain [Tea24a] è un framework open source progettato per costruire applicazioni basate su LLM. Fornisce strumenti avanzati per integrare modelli con dati esterni ed API, creare pipeline con chain e gestire database vettoriali, supportando l'implementazione di sistemi RAG.

4.3.5 BGE-M3

BGE-M3 [BAA24] è un modello di embedding testuale open source per la gestione di dati strutturati e non strutturati multilingue. Il modello permettendo di convertire testo in vettori numerici ad alta dimensionalità.

4.3.6 FAISS

FAISS (Facebook AI Similarity Search) [AI24a] è una libreria open source per la ricerca efficiente di similarità e il clustering di vettori densi. Progettata per gestire dataset su larga scala, FAISS supporta operazioni di ricerca anche su insiemi di vettori che superano la capacità della RAM, grazie a tecniche di indicizzazione avanzate e ottimizzazioni computazionali.

4.4 Dataset

Il dataset è stato creato appositamente per testare il sistema RAG ed è composto da diciannove classi Java:

DateUtilCustom.java Classe personalizzata per gestire le date

GiorniMagici.java Classe per calcolare in maniera particolare dei giorni

BasketballStats.java Classe abstract per statistiche di basket

AdvancedBasketballStats Classe che estende BasketballStats

BasketballTest Classe per testare le statistiche di basket implementate in AdvancedBasketballStats

Altre classi java Non strettamente correlate con le prime due utili per aumentare la base dati sul quale effettuare le ricerche e per testare la capacità di generalizzazione del sistema.

4.5 Scenario base del Caso Studio

DateUtilCustom.java e GiorniMagici.java sono strettamente correlate infatti GiorniMagici.java richiama metodi definiti in DateUtilCustom.java. Andremo a testare il sistema RAG con la seguente query:

- Cosa ritorna il metodo `segnaleWow(LocalDate.of(2025, 2, 14))`?

4.5.1 Codice di riferimento per rispondere alla query

In GiorniMagici.java è presente la seguente funzione:

Listing 4.1: Metodo `segnaleWow` in GiorniMagici.java

```
1 public static String segnaleWow(LocalDate data) {  
2     String wow = "il tuo segnale Wow e': " + DateUtilCustom.getMessaggioMagico(  
3         date);  
4     return wow;  
}
```

Questa funzione richiama il metodo `getMessaggioMagico` presente in DateUtilCustom.java:

Listing 4.2: Metodo `getMessaggioMagico` in DateUtilCustom.java

```
1 public static String getMessaggioMagico(LocalDate datamagica) throws
    DateTimeParseException {
2     DayOfWeek giornoSettimana = datamagica.getDayOfWeek();
3     switch(giornoSettimana) {
4         case MONDAY: return "La magia inizia nel silenzio...";
5         case TUESDAY: return "I sussurri degli antichi si fanno sentire.";
6         case WEDNESDAY: return "Il velo tra i mondi e' sottile oggi.";
7         case THURSDAY: return "L'energia magica e' potente e chiara.";
8         case FRIDAY: return "Attenzione agli incantesimi del crepuscolo.";
9         case SATURDAY: return "Il giorno perfetto per scoprire segreti nascosti.";
10        case SUNDAY: return "Riposa e rigenera il tuo potere magico.";
11        default: return "Il giorno e' avvolto nel mistero...";
12    }
13 }
```

4.5.2 Risultato Atteso

Essendo il 14 Febbraio 2025 un venerdì, ci aspettiamo come risposta:

“il tuo segnale Wow è: **Attenzione agli incantesimi del crepuscolo.**”

4.6 Implementazione

4.6.1 Creazione dei Chunk

I modelli di embedding hanno limiti massimi di input (512-4096 token) per questo spezzare il codice in chunk di dimensioni adeguate è obbligatorio oltre ad essere in ogni caso fondamentale. Inoltre occorre prestare attenzione alla dimensione dei chunk generati, se troppo piccoli riducono il contesto disponibile per il modello mentre se troppo grandi perdono focalizzazione semantica. Per suddividere il file Java in chunk viene utilizzata la libreria **langchain_text_splitters**. Il seguente codice Python mostra come suddividere i file Java in chunk di dimensione fissa, salvando i risultati in un file JSON.

Listing 4.3: Codice Python per la suddivisione dei file Java in chunk

```
1 from langchain_text_splitters import RecursiveCharacterTextSplitter
2 import json
3
```

```

4      # Funzione per caricare e suddividere un file Java
5      def process_file(file_path):
6          with open(file_path, "r", encoding="utf-8") as f:
7              lines = f.readlines()
8
9          # Ricostruisce il testo mantenendo le informazioni sulle linee
10         text = ''.join(lines)
11
12         splitter = RecursiveCharacterTextSplitter(
13             chunk_size=256, #molto basso per prevenire merge di metodi
14             chunk_overlap=64,
15             separators=[
16                 # I seguenti separatori sono stati usati per mantenere i metodi uniti
17                 # Prioritari: catturano la fine dei metodi
18                 "\n}\n\npublic ",
19                 "\n}\n\nprivate ",
20                 "\n}\n\nprotected ",
21                 "\n}\n\nstatic ",
22                 "\n}\n\n// End of method",
23
24                 # Secondari: separatori generici
25                 "\n}\n\n", # Qualsiasi chiusura di blocco
26                 "\n\nclass ", # Inizio nuove classi
27                 "\n@", # Annotazioni
28                 "\n/**", # Javadoc
29                 "\n * ",
30                 "\n"
31             ],
32             keep_separator=False, # per evitare riporto di separatori
33             is_separator_regex=False
34         )
35
36         chunks = splitter.split_text(text)
37         # Calcola le linee esatte per ogni chunk
38         chunk_metadata = []
39         cursor = 0
40         for chunk in chunks:
41             start_line = text.count('\n', 0, cursor) + 1
42             chunk_length = len(chunk)
43             end_line = text.count('\n', 0, cursor + chunk_length) + 1
44             chunk_metadata.append({
45                 "start_line": start_line,
46                 "end_line": end_line,
47                 "text": chunk
48             })
49             cursor += chunk_length
50
51         return chunk_metadata
52
53     # Carica e suddividi i file Java

```

```

54 files = glob.glob("my_project/classi_java_custom/*.java") #["my_project/
    DateUtilCustom.java", "my_project/GiorniMagici.java", "my_project/
    BasketballStats.java", "my_project/Ventunoclassi.java"]
55 all_chunks = []
56
57 for file_path in files:
58     chunks_info = process_file(file_path)
59     for chunk_info in chunks_info:
60         chunk_text = chunk_info["text"]
61
62         # Aggiungi contesto strutturale
63         class_context = ""
64         if "class " in chunk_text:
65             class_name = chunk_text.split("class ")[1].split("{")[0].strip()
66             class_context = f"Classe: {class_name}\n"
67
68         all_chunks.append({
69             "id": len(all_chunks) + 1,
70             "text": f"// File: {file_path}\n{class_context}{chunk_text}",
71             "source": file_path,
72             "type": "code",
73             "start_line": chunk_info["start_line"],
74             "end_line": chunk_info["end_line"],
75             "class": class_context.replace("Classe: ", "") if class_context
                else ""
76         })
77
78 # Salva i chunk in un file JSON
79 with open("chunks.json", "w", encoding="utf-8") as f:
80     json.dump(all_chunks, f, indent=4, ensure_ascii=False)

```

Il chunking è costruito in maniera specifica per **codice java**, i separatori sono stati scelti per tentare di segmentare il codice secondo la struttura tipica dei metodi e delle classi, garantendo che il chunk contenga blocchi di codice "interi". L'opzione `keep_separator=False` crea punti di split più naturali per il codice Java, allineandosi meglio con la struttura dei metodi e delle classi. Per ciascun chunk, se nel testo è presente la stringa `class`, il codice estrae il nome della classe (prendendo il testo che segue `class` fino al primo `{`) e lo utilizza per creare un contesto strutturale (es `Classe: NomeClasse`). Questo contesto viene preappeso al testo del chunk e salvato anche come valore nel campo "class".

Il risultato nel file `chunks.json` è il seguente:

Listing 4.4: Esempio di chunks generati

```

1      [
2          {
3              "id": 1,
4              "text": "// File: my_project/classi_java_custom\\
                    AnalizzatoreRilascio.java\nClasse:
                    AnalizzatoreRilascio\npackage classi_java_custom
                    ;\nimport java.time.LocalDate;\nimport java.time.
                    temporal.ChronoUnit;\nimport java.util.Arrays;\n\
                    npublic class AnalizzatoreRilascio {",
5              "source": "my_project/classi_java_custom\\
                    AnalizzatoreRilascio.java",
6              "type": "code",
7              "start_line": 1,
8              "end_line": 6,
9              "class": "AnalizzatoreRilascio\n"
10         },
11         {
12             "id": 2,
13             "text": "// File: my_project/classi_java_custom\\
                    AnalizzatoreRilascio.java\n* Stima la data di
                    rilascio usando l'algoritmo \"QuantumSchedule\"\n
                    * @param taskCompletati Array di task
                    completati negli ultimi 7 giorni\n        * @param
                    velocitaSviluppo Media story points/giorno",
14             "source": "my_project/classi_java_custom\\
                    AnalizzatoreRilascio.java",
15             "type": "code",
16             "start_line": 6,
17             "end_line": 11,
18             "class": ""
19         },
20         .....continua
21     ]

```

Ogni chunk mantiene:

- Il riferimento al file sorgente
- Il nome della classe

- Le righe di inizio e fine nel file originale
- Il contenuto del codice con la sua struttura

4.6.2 Arricchire i chunk con metadati relativi al codice

Oltre al testo del codice, è importante mantenere informazioni aggiuntive per facilitare la ricerca e l'interpretazione dei chunk. La seguente funzione `extract_method_name` aggiunge una stringa contestuale per ogni chunk che include:

- Il nome del metodo o della classe
- La classe di appartenenza
- Le righe di inizio e fine del codice

Listing 4.5: Funzione `extract_method_name`

```
1  import re
2  def extract_method_name(text):
3      # Pattern per la firma di un metodo in Java
4      method_pattern = r'(?:(public|private|protected|static|final|synchronized|
5          abstract|native)\s+[\w<>\\[\]]+\s+(\w+)\s*([^\s]*)\s*)'
6
7      # Pattern per i costruttori
8      constructor_pattern = r'(?:(public|private|protected)\s+(\w+)\s*([^\s]*)\s*)'
9
10     # Cerca la firma di un metodo
11     matches = re.findall(method_pattern, text)
12     if matches:
13         return matches[0] # Restituisce il primo metodo trovato
14
15     # Cerca costruttori
16     constr_matches = re.findall(constructor_pattern, text)
17     if constr_matches:
18         return constr_matches[0] + " (costruttore)"
19
20     # Cerca chiamate a metodi
21     method_calls = re.findall(r'\.(\w+)\s*(', text)
22     if method_calls:
23         return f"Chiamata a: {method_calls[-1]}"
24
25     return "unknown_method" # Default se non trova nulla
```

4.6.3 Generazione degli Embedding

Gli embedding trasformano i chunk in rappresentazioni vettoriali che catturano il significato semantico. Il seguente codice Python mostra come generare gli embedding e creare un database Faiss. Come precedentemente descritto, il modello di embedding utilizzato è BGE-M3, questo modello usa due rappresentazioni per complementarità, la rappresentazione densa cattura relazioni semantiche mentre quella sparsa cattura relazioni sintattiche. Mentre sul database FAISS ad alta dimensionalità verrà settata la ricerca di somiglianza utilizzando la distanza euclidea tra i vettori.

Listing 4.6: Codice Python per la generazione degli embedding e la creazione di un database FAISS

```

1      import json
2      from sentence_transformers import SentenceTransformer
3      from langchain_community.vectorstores import FAISS
4
5      # 1. Carica i chunk dal file JSON
6      with open("chunks.json", "r", encoding="utf-8") as f:
7          chunks_data = json.load(f)
8
9      chunks = [item["text"] for item in chunks_data]
10
11     # 2. Carica il modello BGE-M3 e genera gli embedding
12     embedder = SentenceTransformer('BAAI/bge-m3')
13     embeddings = embedder.encode(
14         [f"METHOD:{extract_method_name(c['text'])} CLASS:{c['class']} LINES:{c['start_line']}-{c['end_line']} CONTENT:{c['text']}"
15           for c in chunks_data],
16         show_progress_bar=True
17     )
18
19     # 3. Crea un database FAISS
20     vector_store = FAISS.from_embeddings(
21         text_embeddings=list(zip(chunks, embeddings)), # Abbina testi e
22         embedding
23         embedding=embedder, # Modello per future operazioni
24     )
25
26     # 4. Salva il database
27     vector_store.save_local("./faiss_db")
28     print("Database FAISS creato e salvato in ./faiss_db.")

```

Il metodo *encode()* del modello BGE-M3 genera gli embedding per ogni chunk,

chiamando la funzione *extract_method_name* per arricchire il contesto e creare vettori con relazioni semantiche strutturate.

4.6.4 Esecuzione di query sul Database FAISS

Una volta creato il database FAISS, è possibile eseguire ricerche semantiche sui chunk memorizzati:

Listing 4.7: Esecuzione di una query sul database FAISS

```
1  from langchain_community.vectorstores import FAISS
2  from langchain_huggingface import HuggingFaceEmbeddings
3
4  # 1. Carica il modello di embedding nel formato corretto
5  embedder = HuggingFaceEmbeddings(
6      model_name="BAAI/bge-m3",
7      model_kwargs={'device': 'cpu'},
8      encode_kwargs={'normalize_embeddings': True}
9  )
10
11 # 2. Carica il database FAISS esistente
12 vector_store = FAISS.load_local(
13     folder_path="./faiss_db",
14     embeddings=embedder,
15     allow_dangerous_deserialization=True
16 )
17
18 # 3. Query di esempio
19 query = "Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 1, 10))?"
20
21 # 4. Cerca i chunk piu' simili
22 docs = vector_store.similarity_search_with_score(
23     query,
24     k=5,
25     score_threshold=0.90, # bassa similarita'
26     search_type="similarity", # Piu' efficace per il codice
27     lambda_mult=0.5 # Bilancia diversita'/rilevanza
28 )
29
30 # 5. Stampa i risultati con relativo score
31 for i, (doc, score) in enumerate(docs):
32     print(f"Risultato {i+1} (Score: {score:.4f}):")
33     print(doc.page_content)
34     print("-" * 40)
```

Risultati con query base (senza alcun riferimento al metodo utilizzato all'interno di segnale Wow)

- **Query:**
“Cosa ritorna il metodo `segnaleWow(LocalDate.of(2025, 1, 10))`?”
- **Output:** viene restituito il chunk corretto con uno score di similarità di **0.6547**. Questo valore, basato sulla cosine similarity, non è particolarmente alto ma sufficiente per identificare il chunk corretto.

Nota: È importante riscontrare che viene restituito un solo chunk nonostante $k=5$. Questo accade perché nessun altro chunk supera la soglia di similarità impostata. Tale comportamento evidenzia una criticità: la funzione `segnaleWow` richiama un metodo presente nella libreria `DateUtilCustom` che non viene estratto dal Dataset.

Riformulazione query (aggiungendo riferimento al metodo utilizzato all'interno di segnale Wow)

- Per risolvere questo problema, la query è stata riformulata:

“Cosa ritorna il metodo `segnaleWow(LocalDate.of(2025, 1, 10))` che utilizza la funzione `getMessaggioMagico()` della libreria `DateUtilCustom`?”
- L'output fornisce 5 risultati:
 - Primo chunk (**score: 0.5276**): contiene la funzione `segnaleWow`
 - Secondo, terzo e quarto chunk (**scores: 0.7188, 0.7258, 0.7605**): contengono la funzione `getMessaggioMagico`
 - Quinto chunk (**score: 0.8958**): funzione non rilevante relativa alle date

Conclusioni: Sono state riscontrate due problematiche molto rilevanti, la prima riguarda la mancanza di estrazione di metodi da librerie esterne se non esplicitate nella query. Mentre la seconda guarda i chunk estratti, lo score ottenuto non è particolarmente alto e questo con un database più ampio potrebbe portare a risultati non coerenti. Per il secondo punto questa analisi ha portato alla decisione di abbassare `score_threshold` da 0.90 a 0.80, questa piccola correzione risolve in parte la problematica o almeno evita di propagarla ulteriormente preferendo non ottenere risultati piuttosto che ricevere risposte non coerenti.

4.6.5 Creazione della Pipeline RAG

Listing 4.8: Pipeline RAG

```

1  from langchain_community.vectorstores import FAISS
2  from langchain_huggingface import HuggingFaceEmbeddings
3  from langchain_ollama import OllamaLLM
4  from langchain.chains import create_retrieval_chain
5  from langchain.chains.combine_documents import create_stuff_documents_chain
6  from langchain.prompts import PromptTemplate
7
8  # Configurazione embedding
9  embedder = HuggingFaceEmbeddings(
10     model_name="BAAI/bge-m3",
11     model_kwargs={'device': 'cpu'},
12     encode_kwargs={'normalize_embeddings': True}
13 )
14
15 # Caricamento database FAISS
16 vector_store = FAISS.load_local(
17     folder_path="./faiss_db",
18     embeddings=embedder,
19     allow_dangerous_deserialization=True
20 )
21 # Aggiunta del database FAISS al retriever
22 retriever=vector_store.as_retriever(
23     search_kwargs={
24         "k": 5, # Piu' documenti per contesto
25         "score_threshold": 0.80, # medio-bassa similarita' inizialmente
26         "search_type": "similarity", # Piu' efficace per il codice
27         "lambda_mult": 0.5 # Bilancia diversita'/rilevanza
28     }
29 )
30
31 varStyleLLM = "Sei un programmatore che risponde conciso ma sintetico."

```

```

32
33 # Configurazione Template del prompt specifici per i modelli
34 LLAMA_TEMPLATE = """<|begin_of_text|>
35 <|start_header_id|>system"" + varStileLLM + """<|end_header_id|>
36 Contesto: {context}<|eot_id|>
37 <|start_header_id|>user<|end_header_id|>
38 Domanda: {input}<|eot_id|>
39 <|start_header_id|>assistant<|end_header_id|>""
40
41 CODEQWEN_TEMPLATE = """<|im_start|>system "" + varStileLLM + ""
42 {context}<|im_end|>
43 {{ if .Functions }}<|im_start|>functions
44 {{ .Functions }}<|im_end|>{{ end }}
45 <|im_start|>user
46 {input}<|im_end|>
47 <|im_start|>assistant
48 ""
49
50 COMMON_PARAMS = {
51     "temperature": 0.3, #lasciamo una bassa creativita' non vogliamo che
52     inventi risposte
53     "top_p": 0.85 # Bilancia creativita'/controllo nei token generati
54 }
55
56 # Caricamento modello
57 def load_model(model_name):
58     models = {
59         "llama3.2": {
60             "template": LLAMA_TEMPLATE,
61             "params": COMMON_PARAMS
62         },
63         "codeqwen": {
64             "template": CODEQWEN_TEMPLATE,
65             "params": COMMON_PARAMS
66         }
67     }
68     if model_name not in models:
69         raise ValueError(f"Modello non supportato: {model_name}")
70     return OllamaLLM(
71         model=model_name,
72         **models[model_name]["params"]
73     ), PromptTemplate(
74         template=models[model_name]["template"],
75         input_variables=["input", "context"]
76     )
77
78 # Inizializza il modello
79 llm, prompt = load_model("codeqwen")
80
81 # Catena RAG

```

```

81     document_chain = create_stuff_documents_chain(llm, prompt)
82     rag_chain = create_retrieval_chain(
83         retriever,
84         document_chain
85     )
86
87     # Funzione query
88     def ask_ollama(question):
89         try:
90             result = rag_chain.invoke({"input": question})
91             print("DOMANDA:", question)
92             print("RISPOSTA:")
93             print(result["answer"])
94             print("FONTI:")
95             for i, doc in enumerate(result["context"], 1):
96                 print(f"{i}. {doc.page_content[:150]}...")
97                 if 'source' in doc.metadata:
98                     print(f"   Fonte: {doc.metadata['source']}")
99             print("-" * 80)
100         except Exception as e:
101             print(f"ERRORE: {str(e)}")
102
103     # Esempio d'uso
104     if __name__ == "__main__":
105         ask_ollama("Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 1, 10))
106             che utilizza la funzione getMessaggioMagico() della libreria
107             DateUtilCustom?")
108         #ask_ollama("Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 1, 10))
109             ?")

```

Spiegazione Pipeline del RAG

Seguendo la struttura precedentemente creata, per eseguire l'embedder della query di input viene utilizzato il modello BAAI/bge-m3 e caricato il database FAISS contenente la **knowledge base**. La chiamata iniziale alla funzione *ask_ollama()* richiede come parametro la **query di input** che verrà processata dalla pipeline RAG. Sfruttando le funzionalità della libreria LangChain [Lan24b], **result** sarà un array contenente la risposta("answer") e il contesto("context") fornito alla query.

rag_chain.invoke()

Questa funzione esegue la catena RAG creata tramite il metodo *create_retrieval_chain()* che prende come parametri il retriever e il document chain.

- la funzione `create_stuff_documents_chain()` carica una catena di documenti prendendo in input il modello LLM e il template del prompt.
- `load_model()` carica il modello LLM e il template del prompt in base al modello scelto sfruttando OllamaLLM e PromptTemplate.

Temperature

Per i due LLM è stata data una temperature molto bassa **0.3** in modo da garantire da parte dei LLM risposte coerenti e precise senza provi ad inventarle.

Top_p

Il parametro `top_p` è stato impostato a 0.85 per bilanciare creatività e controllo nei token generati.

System

Come parametro di sistema da passare al LLM è stato esplicitamente richiesto di rispondere in italiano come esperto di programmazione ma solo se è sicuro.

4.7 Test Sistema RAG

Valutiamo se il sistema RAG è in grado di rispondere in maniera coerente alla query proposta. Ricordiamo che il risultato atteso è: **“il tuo segnale Wow è: Attenzione agli incantesimi del crepuscolo.”**

4.7.1 Query base senza riferimenti al metodo utilizzato all'interno di segnaleWow

```
“Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 2, 14))?”
```

Fonti aggiunte al prompt

Il RAG aggiunge solo il chunk dove è presente la funzione `segnaleWow` e non il chunk con la funzione `getMessaggioMagico` della libreria `DateUtilCustom` per

questo le risposte dei due modelli sono incomplete:

Output con LLM Llama3.2

L'output ottenuto utilizzando il modello Llama3.2 è stato:

“Il metodo `segnaleWow` restituisce una stringa che contiene un messaggio magico associato alla data specificata. In questo caso, la data è il 14 Febbraio 2025. La risposta esatta sarebbe: ”il tuo segnale Wow è : [messaggio magico]” dove [messaggio magico] è il risultato dell'applicazione di `DateUtilCustom.getMessaggioMagico(date)`.”

Modifica Temperature

CodeQwen provava a dare risposta anche senza avere tutte le informazioni necessarie, ho deciso di abbassare la temperatura da 0.3 a 0.2 per vedere se il modello CodeQwen avrebbe risposto in maniera più precisa. Cosa che è avvenuta:

Output con LLM CodeQwen

Utilizzando invece il modello CodeQwen, la risposta ottenuta è stata:

“Se si chiama il metodo `'segnaleWow'` con un'istanza di `'LocalDate'` che rappresenta la data `"14 febbraio 2025"`, il valore restituito sarà una stringa che indica il segnale Wow associato a tale data. `"java String result = GiorniMagici.segnaleWow(LocalDate.of(2025, 2, 14)); System.out.println(result);` “ Il metodo `'getMessaggioMagico'` viene richiamato su un'istanza di `'DateUtilCustom'`, passando la data `"14 febbraio 2025"` come parametro. Questo metodo presumibilmente restituisce un messaggio magico associato a tale data, ad esempio `"La data del New Year è una data speciale"`. Il risultato finale sarà: `" il tuo segnale Wow è : La data del New Year è una data speciale"`

4.7.2 Query Completa con riferimenti al metodo utilizzato all'interno di segnaleWow

```
‘‘Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 2, 14))  
che utilizza la funzione getMessaggioMagico() della libreria  
DateUtilCustom?’’
```

Fonti aggiunte dal RAG al prompt

In questo caso il RAG aggiunge 5 chunk, ovvero oltre a quello relativo alla funzione `segnaleWow` anche i chunk relativi alla funzione `getMessaggioMagico` della libreria `DateUtilCustom`. Ne consegue che **le risposte date dai due modelli sono coerenti con quanto atteso.**

Output con LLM Llama3.2

“Il metodo ‘segnaleWow’ restituisce una stringa che contiene il messaggio magico per la data specificata. Per determinare il messaggio esatto, dobbiamo analizzare la data fornita: ‘`LocalDate.of(2025, 2, 14)`’. La data è il 14 febbraio 2025. Il giorno della settimana corrisponde a ‘FRIDAY’. Quindi, il messaggio magico restituito dal metodo ‘`getMessaggioMagico`’ sarà: ” **Attenzione agli incantesimi del crepuscolo.**”

Output con LLM CodeQwen

“Se si chiama il metodo ‘segnaleWow’ con una data di ‘`LocalDate.of(2025, 2, 14)`’, utilizzando la funzione ‘`getMessaggioMagico()`’ della libreria ‘`DateUtilCustom`’, il risultato sarà: “ Il tuo segnale Wow è : **Il giorno perfetto per scoprire segreti nascosti.** “ Questo è dato che la data 2025-02-14 cade mercoledì, quindi il metodo ‘`getMessaggioMagico()`’ restituisce il messaggio ”Il giorno perfetto per scoprire segreti nascosti.”

4.7.3 Commento risultati ottenuti

I risultati ottenuti mostrano come il sistema RAG sia in grado di rispondere in maniera coerente alla query proposta. La ricerca dei chunk più simili funziona

correttamente soprattutto se si scrive la richiesta in maniera più dettagliata possibile. CodeQwen ha sbagliato a calcolare il giorno della settimana a causa di un suo errore nel calcolare il giorno della settimana corrispondente alla data fornita come parametro ma la risposta utilizza correttamente il metodo `getMessaggioMagico()`.

4.8 Valutazione del RAG con llm as a judge

Per eseguire una valutazione più ampia del sistema usiamo l'approccio *"llm as a judge"* per valutare automaticamente quanto prodotto dal sistema RAG. Generiamo 30 domande sulle quali sarà richiesta risposta al sistema RAG e successivamente eseguita una valutazione automatizzata delle risposte prodotte da parte di più LLM. Il dataset originale è stato arricchito da altre classi java generate dai LLM Deepseek e Mistral.

4.8.1 Domande

Passando un file contenente tutte le librerie a NotebookLM, sono state generate 30 domande per valutare il sistema RAG. La domanda fatta al LLM è stata:

```
“Dalle mie classi genera 30 domande/risposte per valutare il  
mio rag la prima è: Cosa ritorna il metodo segnaleWow(LocalDate.of(2025,  
2, 14)) che utilizza la funzione getMessaggioMagico() della  
libreria DateUtilCustom?”
```

Il risulta è stato il seguente:

Listing 4.9: Domande generate da NotebookLM

```
1 [
2   {
3     "id": 1,
4     "question": "Cosa ritorna il metodo segnaleWow(LocalDate.of(2025, 2, 14))  
che utilizza la funzione getMessaggioMagico() della libreria  
DateUtilCustom?"
5   },
6   {
7     "id": 2,
8     "question": "La classe AnalizzatoreRilascio contiene un metodo chiamato  
stimaDataRilascio. Quali sono i due parametri di input richiesti da  
questo metodo?"
```

```
9      },
10     {
11         "id": 3,
12         "question": "Nella classe AnalizzatoreRilascio, come viene calcolato il
13                     numero di task rimanenti nel metodo stimaDataRilascio?"
14     },
15     {
16         "id": 4,
17         "question": "Qual e' il valore di soglia critica per l'indice di rischio
18                     rilascio (IRR) nella classe AnalizzatoreRilascio?"
19     },
20     {
21         "id": 5,
22         "question": "Quali sono i parametri di input del metodo
23                     calcolaProbabilitaSuccesso nella classe AnalizzatoreRilascio e come
24                     viene calcolata la probabilita' di successo?"
25     },
26     {
27         "id": 6,
28         "question": "Qual e' lo scopo del metodo stimaTempoRimanente nella classe
29                     AnalizzatoreRilascio e quali parametri accetta?"
30     },
31     {
32         "id": 7,
33         "question": "Nella classe BasketballStats, qual e' la formula utilizzata
34                     per calcolare l'efficienza di un giocatore nel metodo
35                     calcolaEfficienzaGiocatore?"
36     },
37     {
38         "id": 8,
39         "question": "Quali sono i criteri utilizzati nel metodo valutaTiro della
40                     classe BasketballStats per valutare la qualita' di un tiro?"
41     },
42     {
43         "id": 9,
44         "question": "Cosa restituisce il metodo analisiStatisticheSquadra della
45                     classe BasketballStats?"
46     },
47     {
48         "id": 10,
49         "question": "Quali sono gli input del metodo previsioneVincitore nella
50                     classe BasketballStats e cosa rappresentano?"
51     },
52     {
53         "id": 11,
54         "question": "Come viene calcolato il margine nel metodo
55                     previsioneVincitore della classe BasketballStats?"
56     },
57     {
58         "id": 12,
```

```
48         "question": "Cosa rappresenta l'input del metodo calcolaMomentum nella
49         },
50         {
51             "id": 13,
52             "question": "Qual e' il requisito per la lunghezza della chiave segreta
53             nel metodo cifraturaVortex della classe CifratoreAziendale?"
54         },
55         {
56             "id": 14,
57             "question": "Cosa fa il metodo mascheraDatiSensibili nella classe
58             TrasformatoreDati?"
59         },
60         {
61             "id": 15,
62             "question": "Nella classe DateUtilCustom, descrivi cosa fa il metodo
63             formatDate(Date date) e fornisci un esempio del formato di output."
64         },
65         {
66             "id": 16,
67             "question": "Qual e' la differenza tra i metodi formatDate(Date date) e
68             formatDate(Date date, String format) nella classe DateUtilCustom?"
69         },
70         {
71             "id": 17,
72             "question": "Cosa puo' accadere se si utilizza il metodo parseDate della
73             classe DateUtilCustom con una stringa che non corrisponde al formato
74             specificato?"
75         },
76         {
77             "id": 18,
78             "question": "Nella classe DateUtilCustom, cosa calcola il metodo
79             getDifferenceInDays(Date startDate, Date endDate)?"
80         },
81         {
82             "id": 19,
83             "question": "Cosa fa il metodo addDays(Date date, int days) nella classe
84             DateUtilCustom?"
85         },
86         {
87             "id": 20,
88             "question": "Come si verifica se una data e' nel passato usando la classe
89             DateUtilCustom?"
90         },
91         {
92             "id": 21,
93             "question": "Cosa fa il metodo giorniAlmiocompleannoSpecial(Date
94             dataNascita, String nome) nella classe DateUtilCustom?"
95         },
96         {
97             "id": 22,
98             "question": "Cosa fa il metodo getGiorniAlProssimoCompleannoSpecial(Date
99             dataNascita, String nome) nella classe DateUtilCustom?"
100        }
```

```
87     "id": 22,  
88     "question": "In ElaboratoreLinguaggio, come viene calcolato il punteggio  
      di sentimento di un testo?"  
89   },  
90   {  
91     "id": 23,  
92     "question": "Qual e' lo scopo del metodo estraiEntitaNominate nella classe  
      ElaboratoreLinguaggio?"  
93   },  
94   {  
95     "id": 24,  
96     "question": "Cosa fa il metodo applicaTemplate nella classe  
      GestoreConfigurazioni?"  
97   },  
98   {  
99     "id": 25,  
100    "question": "In GestoreConoscenza, cosa fa il metodo estraiMetadati?"  
101  },  
102  {  
103    "id": 26,  
104    "question": "Qual e' lo scopo del metodo generaIdentitaDigitale nella  
      classe GestoreIdentita e cosa prende come input?"  
105  },  
106  {  
107    "id": 27,  
108    "question": "Cosa verifica il metodo verificaIdentita nella classe  
      GestoreIdentita?"  
109  },  
110  {  
111    "id": 28,  
112    "question": "Quali controlli vengono eseguiti all'interno del metodo  
      generaChiaveAttivazione della classe GestoreLicenze?"  
113  },  
114  {  
115    "id": 29,  
116    "question": "Cosa calcola il metodo calcolaIndiceManutenibilita della  
      classe IspezionatoreCodice?"  
117  },  
118  {  
119    "id": 30,  
120    "question": "In MetricheAgili, cosa rappresenta il fattoreComplessita' nel  
      metodo calcolaVelocityScore e qual e' il suo range?"  
121  }  
122 ]
```

4.8.2 Punteggio delle domande

Per valutare le domande generate da **LMNotebook**, è stato chiesto a **GPT4o** e a **Mistral** di fornire un "punteggio totale" che indichi la capacità di rispondere alla domanda senza ambiguità con il contesto dato. Date la vostra risposta su una scala da 1 a 5, dove 1 significa che la domanda non è affatto risolvibile in base al contesto e 5 significa che la domanda è chiaramente e inequivocabilmente risolvibile in base al contesto.

Risultati

I modelli hanno valutato le domande generate da LMNotebook con punteggi diversi:

- **Mistral:** 145 su 150
- **GPT4o:** 121 su 150

GPT4o mi ha fornito anche una tabella riepilogativa con i punteggi di ogni domanda:

ID	Domanda	Punteggio (1-5)	Motivazione
1	Metodo <code>segnaleWow</code> e <code>getMessaggioMagico()</code>	5	Impossibile senza accesso al codice specifico.
2	Parametri di <code>stimaDataRilascio</code>	5	I parametri sono arbitrari e non deducibili senza documentazione.
3	Calcolo task rimanenti in <code>stimaDataRilascio</code>	5	La logica interna non è prevedibile senza codice.
4	Soglia critica dell'IRR	5	Questo valore è arbitrario e definito solo nel codice/documentazione specifica.
5	Parametri e calcolo di <code>calcolaProbabilitaSuccesso</code>	5	La formula è sconosciuta senza accesso diretto.
6	Scopo e parametri di <code>stimaTempoRimanente</code>	5	Dipende dalla logica implementata.

ID	Domanda	Punteggio (1-5)	Motivazione
7	Formula di calcolaEfficienzaGiocatore	4	Se usa metriche standard NBA, potrebbe essere ipotizzabile, altrimenti no.
8	Criteri di valutaTiro	4	Se segue principi di analisi statistica sportiva, si può ipotizzare, ma senza certezza.
9	Output di analisiStatisticheSquadra	4	Può essere stimato, ma la struttura esatta non è nota.
10	Input e significato di previsioneVincitore	4	Alcuni parametri sono prevedibili, ma i dettagli precisi no.
11	Calcolo del margine in previsioneVincitore	5	La formula specifica è ignota.
12	Input di calcolaMomentum	4	Se segue definizioni standard, potrebbe essere deducibile.
13	Lunghezza chiave in cifaturaVortex	5	È una regola arbitraria del software specifico.
14	Scopo di mascheraDatiSensibili	3	Il concetto è generico, ma l'implementazione varia.
15	Scopo e output di formatDate	2	È un metodo comune, altamente prevedibile.
16	Differenza tra i due formatDate	2	Differenza standard tra metodi di formattazione con/senza specifica del formato.
17	Comportamento di parseDate con input errato	3	Tipicamente lancia un'eccezione, ma la gestione può variare.
18	Funzione getDifferenceInDays	2	Metodo comune, implementazione prevedibile.
19	Funzione addDays	2	Standard in qualsiasi utility di date.

ID	Domanda	Punteggio (1-5)	Motivazione
20	Verifica se una data è nel passato	2	Operazione semplice con <code>isBefore()</code> .
21	Scopo di <code>giorniAlmiodompleannoSpecial</code>	5	Nome ambiguo, logica ignota.
22	Calcolo punteggio di sentimento	4	Se segue NLP standard, potrebbe essere ipotizzabile.
23	Scopo di <code>estraiEntitaNominate</code>	3	NLP standard, facile da descrivere.
24	Funzione <code>applicaTemplate</code>	5	Nome troppo generico, può fare qualsiasi cosa.
25	Funzione <code>estraiMetadati</code>	4	Dipende da cosa si intende per metadati nel contesto specifico.
26	Scopo e input di <code>generaIdentitaDigitale</code>	5	Implementazione sconosciuta, input indefiniti.
27	Verifica di <code>verificaIdentita</code>	4	Probabilmente autenticazione, ma non si può sapere esattamente come.
28	Controlli in <code>generaChiaveAttivazione</code>	5	Dipende dalle policy aziendali specifiche.
29	Calcolo di <code>calcolaIndiceManutenibilita</code>	5	Nessuno standard universale, dipende dalla formula interna.
30	<code>fattoreComplessita</code> in <code>calcolaVelocityScore</code>	5	Senza definizione esatta, non si può dedurre.

Verranno usati come riferimento i punteggi dati da **GPT4o**, nel dettaglio hanno questa corrispondenza:

- Domande con punteggio 5: Non risolvibili senza accesso al codice/documentazione.
- Domande con punteggio 4: Difficili, ma in alcuni casi il modello può ipotizzare una risposta sensata.

- Domande con punteggio 3: Risolvibili parzialmente con conoscenze standard, ma con margini di errore.
- Domande con punteggio 2: Generalmente risolvibili perché rientrano in pattern comuni di programmazione.

4.8.3 Valutazione risultati risposte sistema RAG

Il sistema RAG ha elaborato le domande e fornito risposta salvando il risultato in un file JSON. Questo file è stato valutato da **GPT4o** e **Mistral** per valutare la coerenza delle risposte.

Chapter 5

Conclusioni

da completare

5.1 Impatto sullo Sviluppo Software

L'integrazione di strumenti basati su AI nel processo di sviluppo software sta rivoluzionando il settore. Durante il periodo di sviluppo di questa tesi (Ottobre 2024 - Febbraio 2025), abbiamo osservato:

- Rapida evoluzione degli strumenti di AI per lo sviluppo software
- Crescente disponibilità di soluzioni open source
- Miglioramento continuo nelle capacità di generazione e comprensione del codice

5.2 Sfide e Prospettive Future

Bibliography

- [AI24a] Meta AI. Faiss: A library for efficient similarity search, 2024. Facebook AI Similarity Search library documentation. URL: <https://faiss.ai/>.
- [AI24b] Meta AI. Llama-3.2-3b: Open foundation and fine-tuned chat models, 2024. URL: <https://huggingface.co/meta-llama/Llama-3.2-3B>.
- [BAA24] BAAI. Bge-m3: A multi-modal model understanding images and text, 2024. HuggingFace model repository for BGE-M3, a multi-modal model for image and text understanding. URL: <https://huggingface.co/BAAI/bge-m3>.
- [Doc24] Huggingface Docs. Lora, dec 2024. URL: <https://huggingface.co/docs/diffusers/training/lora>.
- [Doc25] GitHub Docs. Asking github copilot questions in your ide, jan 2025. URL: <https://docs.github.com/en/copilot/using-github-copilot/asking-github-copilot-questions-in-your-ide#ai-models-for-copilot-chat>.
- [Fac24a] Hugging Face. Llm judge: Automated evaluation cookbook, 2024. Guide for automated LLM evaluation using judge models. URL: https://huggingface.co/learn/cookbook/llm_judge.
- [Fac24b] Hugging Face. Rag evaluation cookbook, 2024. Guide for evaluating Retrieval Augmented Generation systems. URL: https://huggingface.co/learn/cookbook/rag_evaluation.

- [FGT⁺20] Zhangyin Feng, Daya Guo, Duyu Tang, Nan Duan, Xiaocheng Feng, Ming Gong, Linjun Shou, Bing Qin, Ting Liu, Daxin Jiang, et al. Codebert: A pre-trained model for programming and natural languages. *arXiv preprint arXiv:2002.08155*, 2020. URL: <https://arxiv.org/abs/2002.08155>.
- [Git24] GitHub. Github copilot is more than a tool, it's an ally, dec 2024. URL: <https://www.linkedin.com/pulse/github-copilot-more-than-tool-its-ally-github-qhnoc/>.
- [JWS⁺24] Juyong Jiang, Fan Wang, Jiasi Shen, Sungju Kim, and Sunghun Kim. A survey on large language models for code generation, 2024. URL: <https://arxiv.org/abs/2406.00515>, doi:10.48550/ARXIV.2406.00515.
- [Lan24a] LangChain. Langchain integration: Ollama, 2024. Documentation for LangChain Ollama integration. URL: <https://python.langchain.com/docs/integrations/llms/ollama/>.
- [Lan24b] LangChain. Langchain retrieval chain documentation, 2024. Create Retrieval Chain API reference. URL: https://python.langchain.com/api_reference/langchain/chains/langchain.chains.retrieval.create_retrieval_chain.html.
- [Met24] Meta. Llama-3.3-70b-instruct, dec 2024. URL: <https://huggingface.co/meta-llama/Llama-3.3-70B-Instruct>.
- [Oll24] Ollama. Ollama documentation, 2024. GitHub repository. URL: <https://github.com/ollama/ollama/tree/main/docs>.
- [Res24] Restack. Understanding tokenization in machine learning, 2024. Guide to tokenization concepts and implementation in ML. URL: <https://www.restack.io/p/tokenization-knowledge-answer-machine-learning-cat-ai>.
- [SBO23] Ahmed R. Sadik, Sebastian Brulin, and Markus Olhofer. Coding by design: Gpt-4 empowers agile model driven development, 2023.

- URL: <https://arxiv.org/abs/2310.04304>, doi:10.48550/ARXIV.2310.04304.
- [Sta24] Stanford University. Code generation with large language models, 2024. CS224G Course Materials. URL: <https://web.stanford.edu/class/cs224g/slides/Code%20Generation%20with%20LLMs.pdf>.
- [Tea24a] LangChain Team. Langchain documentation, 2024. URL: <https://python.langchain.com/docs/introduction/>.
- [Tea24b] Qwen Team. Codeqwen1.5: A code-specialized language model, 2024. URL: <https://qwenlm.github.io/blog/codeqwen1.5/>.
- [Tea24c] Qwen Team. Qwen2.5-coder-3b: A code-specialized language model, 2024. URL: <https://huggingface.co/Qwen/Qwen2.5-Coder-3B>.
- [WDS⁺20] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, et al. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45. Association for Computational Linguistics, 2020. URL: <https://huggingface.co/docs/transformers/index>.
- [WFS⁺24] Ziyi Wang, Hui Fang, Weiyi Sun, Moshi Wu, Yixin Chen, and Rui Wang. A survey of code llms: A journey from code completion to ai-powered programming. *arXiv preprint arXiv:2412.08821*, 2024. URL: <https://arxiv.org/abs/2412.08821>, doi:10.48550/arXiv.2412.08821.